DALL-E

https://github.com/kuprel/min-dalle

https://blog.csdn.net/qq_36332660/article/details/134273737

https://blog.csdn.net/Friedrichor/article/details/128086733

使用AutoDL时下载模型时的问题

https://blog.csdn.net/weixin_46141492/article/details/135206086?spm=1001.2101.3001.6650.3&utm_medium=distribute.pc_relevant.none-task-blog-2~default~CTRLIST~Rate-3-135206086-blog-131850846.235^v43^pc_blog_bottom_relevance_base2&depth_1-utm_source=distribute.pc_relevant.none-task-blog-2~default~CTRLIST~Rate-3-135206086-blog-131850846.235^v43^pc_blog_bottom_relevance_base2

min-dalle代码解读

最外层参数

```
class MinDalle:
    def __init__(
        device: str = None,
        is_mega: bool = True,
        is_reusable: bool = True,
        is_verbose = True
    ):
        if device == None:
            device = 'cuda' if torch.cuda.is_available() else 'cpu'
        if is_verbose: print("using device", device)
        self.device = device
        self.is_mega = is_mega
        self.is_reusable = is_reusable
        self.dtype = dtype
        self.is_verbose = is_verbose
        self.text_token_count = 64
        self.layer_count = 24 if is_mega else 12
        self.attention_head_count = 32 if is_mega else 16
        self.embed_count = 2048 if is_mega else 1024
        self.glu_embed_count = 4096 if is_mega else 2730
        self.text_vocab_count = 50272 if is_mega else 50264
        self.image_vocab_count = 16415 if is_mega else 16384
```

```
image = model.generate_image(
    text = "fish and chips in a bowl",
    seed = -1,
    grid_size = 4,
    is_seamless = False,
    temperature = 1,
    top_k = 256,
    supercondition_factor = 32,
    is_verbose = False
)
```

generate_raw_image_stream():

image_count = grid_size ** 2

text_tokens 形(2，64)

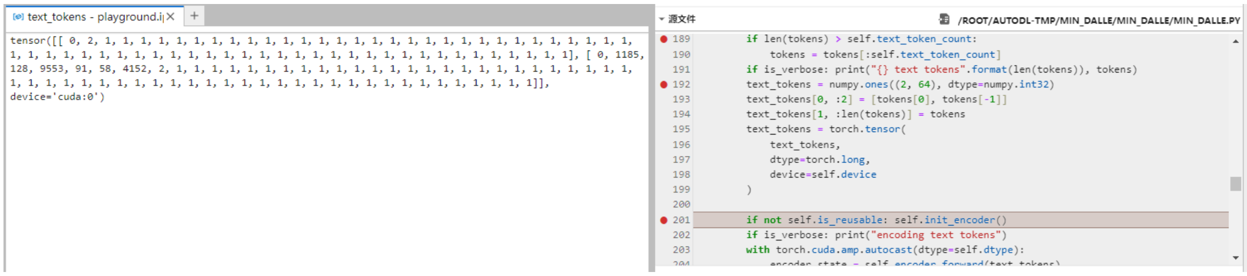

expanded_indices创建时

text_tokens经过expanded_indices索引后 形如(32, 64)

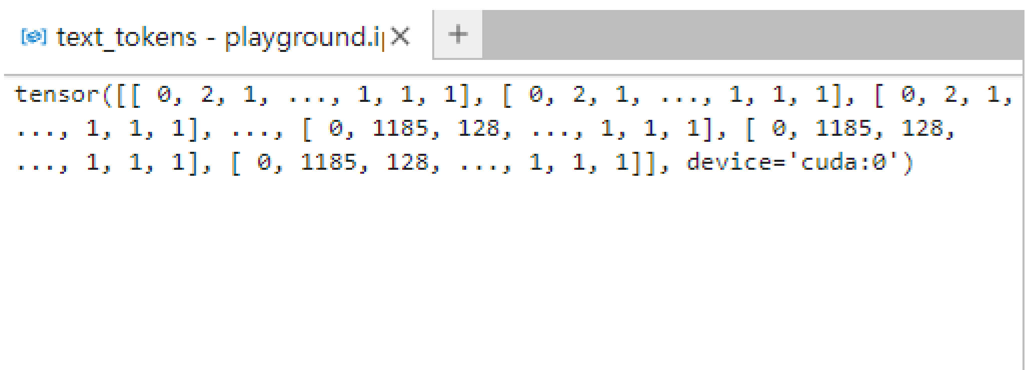

encoder_state由DalleBartEncoder的forward()创建时形如(2, 64, 2048)

经expanded_indices索引后 形如(32, 64, 2048)

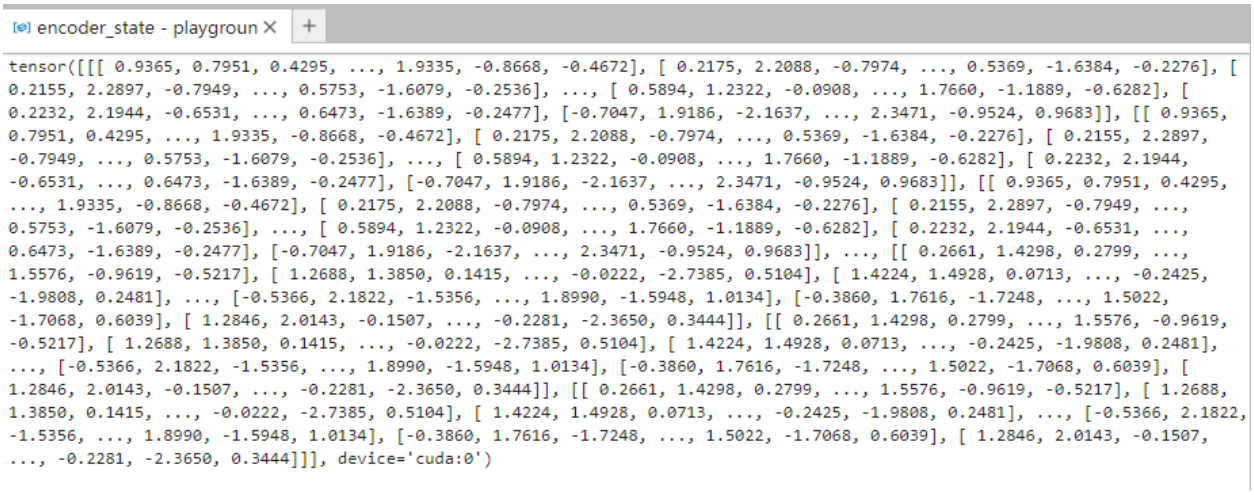

attention_mask由text_tokens创建时形如(32, 1, 1, 64)

attention_state由torch.zero创建时形如(24, 64, 256, 2048)（self.layer_count, image_count * 4, IMAGE_TOKEN_COUNT, self.embed_count)

image_tokens由torch.full创建时形如(16, 257) （image_count, IMAGE_TOKEN_COUNT + 1)

token_indices经由torch.arange创建时形如(256）IMAGE_TOKEN_COUNT

settings 创建时内涵三个元素，分别是 [temperature, top_k, supercondition_factor] 这三个参数都在调用generate_images的API接口时指定

最后是一个for i in range(IMAGE_TOKEN_COUNT)的循环：

调用self.decoder.sample_tokens方法赋值给 image_tokens[:, i + 1], attention_state

再在一定条件下调用 self.image_grid_from_tokens 通过yield迭代输出

DalleBartEncoder类

forward()

attention_mask

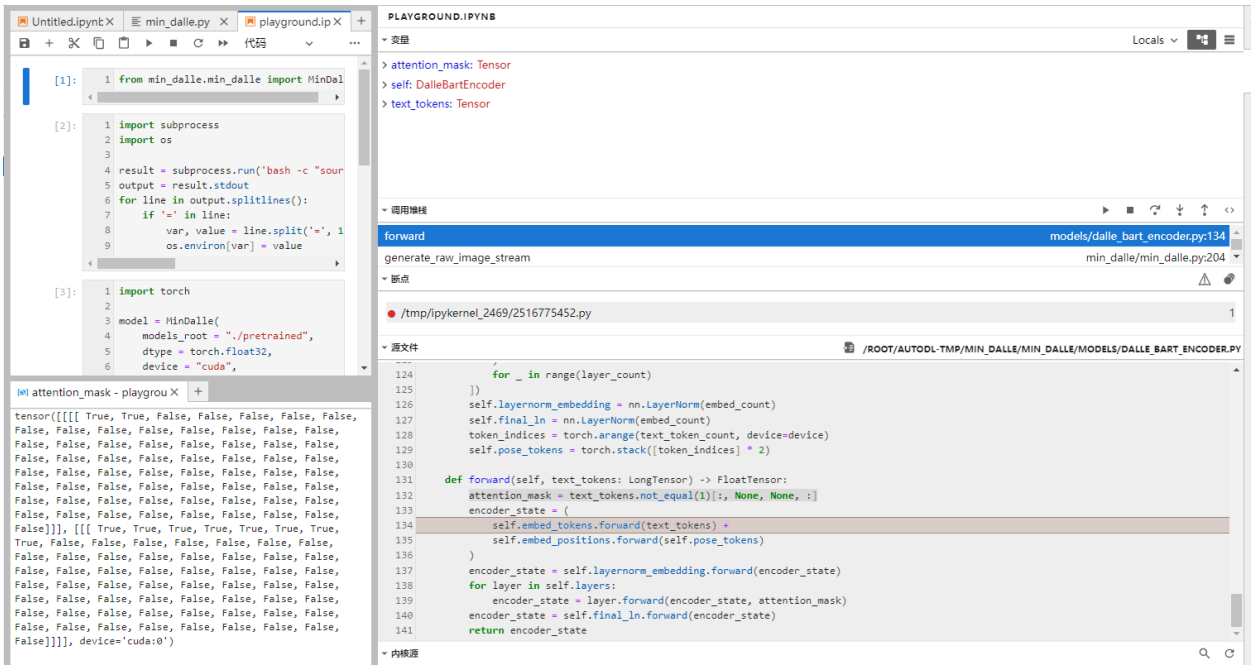

encoder_state 创建后形如(2, 64, 2048)

经self.layernorm_embedding后shape不变

经self.layers后shape不变

经self.final_ln.forward后shape不变

返回encoder_state

DalleBartDecoder类

sample_tokens()

传入的参数中, prev_tokens形如（16, 1), token_index形如 (1,)

经由forward()方法返回 logits, attention_state

logits经过 logits[:, -1, : 2 ** 14] 索引后形如（32，16384）

在经过下一行形如（16， 16384）

利用supercondition_factor对logits的值进行了调整，这里追根溯源维度数32出现的原因是一开始的expanded_indices的复制扩张，expanded_indices = [0] * image_count + [1] * image_count 但具体为什么有待探究

supercondition_factor的作用，注意到text_token的维度1上的数是2，而且根据上面text_token的会发现，只有后半截（也就是text_token[1]）中包含真正的描述文本的字典编码，text_token前半截(text_token[0])中开头token索引0和结尾token索引2是相连的，其他都是1，1这里很有可能就是填充token的索引。而最后对logits的处理，如果supercondition_factor越大，text_token中后半截所对应的这部分logits的比重越大，生成的图像越遵循文本。

logits_sorted形如（16，16384）

logits在接下来的操作中shape不变

通过torch.multinomial(logits, 1)[:, 0] 获得image_tokens形如（16，）

最后抽样出的image_tokens 形如（16，1）

几个疑问：

- 为什么统一减去最大值？GPT回答：为了数值稳定性，防止溢出。
- temperature的作用？GPT回答：调整 logits 的尖锐程度，使得概率分布更加平滑。

forward()

传入的参数：attention_mask　attention_state　encoder_state　prev_tokens　token_index

token_index经 .unsqueeze(0).repeat(image_count * 2, 1) 后形如（32，1）

prev_tokens经 .repeat(2, 1)后形如（32，1）

decoder_state 由self.embed_tokens的forward创建时形如（32，1，2048）

经过self.embed_position, self.layernorm_embedding后形如（32，1，2048）

最后是通过多个相同的DecoderLayer类模块的forward

传入的参数有decoder_state encoder_state attention_state[i] attention_mask token_index

最后decoder_state经过self.final_ln后形状依然是（32，1，2048）

decoder_state经过self.lm_head后得到logits

self.lm_head的定义是

nn.Linear(embed_count, image_vocab_count + 1, bias=False)

形如

nn.Linear(2048, 16415 + 1, bias=False)

logits形如（32，1，16416）

这个方法返回logits attention_state

其中attention_state形如（24，64，256，2048）跟定义之初shape相同

参考

```python
def forward(self, is_seamless: bool, z: LongTensor) -> FloatTensor:
    # 计算输入张量的尺寸，并根据标记数量调整网格大小
    # grid_size为输入平面的一边的长度（假定输入为正方形）
    # token_count是每边的长度乘以16，计算出一个扩展的尺寸，这有助于后续的嵌入和图像重建
    grid_size = int(sqrt(z.shape[0]))
    token_count = grid_size * 2 ** 4

    # 根据是否需要无缝拼接，处理输入张量的形状
    if is_seamless:
        # grid_size 是原始图像在 (variable) grid_size: int 即16）表示每个块在行和列上的细分
        # 如果 z 表示一个 256x25                              个标记表示，grid_size 可能是 16，意味着图像被分割成 16x16 的块，每块包含 16x16 个像素（或标记）
        z = z.view([grid_size, grid_size, 2 ** 4, 2 ** 4])
        # flatten(1, 2) 将每个 grid_size x grid_size 块内的数据打平
        # transpose(1, 0) 交换块级别的行和列，它帮助保持在嵌入和后续处理中空间的连续性
        # 第二次 flatten(1, 2) 执行后，z 包含了一个完全线性化的长向量
        z = z.flatten(1, 2).transpose(1, 0).flatten(1, 2)
        # flatten() 和 unsqueeze(1) 进一步确保张量是一个单列的二维张量，每行是一个标记
        z = z.flatten().unsqueeze(1)
        # self.embedding 将每个标记映射到一个256维的向量，即 embed_count
        z = self.embedding.forward(z)
        # 将嵌入后的向量重构成一个三维特征图
        z = z.view((1, token_count, token_count, 2 ** 8))
    else:
        # 仅将每个标记映射为嵌入向量，然后重新排列成适合进一步处理的形式
        z = self.embedding.forward(z)
        z = z.view((z.shape[0], 2 ** 4, 2 ** 4, 2 ** 8))

    # 调整张量维度以匹配卷积网络的输入要求
    z = z.permute(0, 3, 1, 2).contiguous()
```